

王博

电话: 18372677551 | 籍贯: 湖北十堰
邮箱: 2075827497@qq.com | 年龄: 24
岗位目标: 模型量化部署工程师



教育经历

2020 年 8 月~2024 年 7 月	上海大学	自动化	本科
2024 年 9 月~2027 年 7 月	上海大学	仪器科学与技术	研究生

在校经历: 本科 GPA3.4/4(专业 15%), 获得过一次研究生一等奖学金, 一次研究生二等奖学金, 发表 EI 论文 1 篇 (一作)、软著 3 篇 (一作)

实习经历

2025 年 7 月 ~ 至今	酷睿微电子	模型量化部署	实习
-----------------	-------	--------	----

工作内容: 负责将多种深度学习模型转换为 ONNX 格式, 并针对公司自研 NPU (AR9401、AR8040 系列) 完成全流程部署优化。核心工作涵盖模型图优化、PTQ 量化、精度验证、性能评估及最终固件生成。

核心职责:

- onnx 模型图优化: 执行常量折叠、算子融合、死代码消除等图优化策略, 针对 NPU 指令集特性, 完成 GRU、Mod 等复杂算子的拆分与适配。
- 常见模型的 PTQ 量化: 在此基础上使用 MinMax 方法对模型进行 PTQ int8 量化, 实现全 8 bit 推理计算, 最终产生 npubin 上板文件。Vggv5 模型最终 MAC 利用率达 92.2%, SRAM 带宽占比 44.4%。量化模型体积降为原本的 30%, 与 FP32 相比输出的余弦相似度达到 0.9989, MAE 仅 0.0069, 精度损失极小。
- 超分模型的 PTQ 量化训练: 通过 torch.fx 将 ONNX 模型转为 torch 图, 并插入量化/反量化节点, 采用 MX 量化方案实现 A8W6 量化。为进一步提升量化性能, 引入 Brecq 进行块级微调优化, 并在权重量化舍入阶段采用 Adaround 策略进行退火优化。最终量化模型与原 FP32 模型的 PSNR 达到 42dB, 有效维持了超分任务的视觉效果。
- 编写量化算子 ONNX Runtime 的计算 kernel: 利用 ONNX Runtime 模拟 NPU 上的计算流, 以提前验证量化后的精度偏差。同时, 将卷积与 DepthToSpace 等算子融合为单一 Kernel, 减少数据搬运次数, 显著提升推理效率。最终量化 ONNX 模型的输出与 Torch 量化模型结果高度一致, 验证了模拟流程的可靠性。

项目经历

基于 TensorRT 的自定义算子插件开发与 SwinIR 超分模型 INT8 量化部署

模型转换: 将 SwinIR 模型的卷积与 depthTospace 算子合并为自定义的 convdts 算子并导出为 onnx 模型, 基于 IPluginV3 编写插件并完成其 CUDA 计算的实现, 扩展 onnx-tensorRT 解释器, 完成其对于 convdts 的支持, 能够直接从 onnx 模型转为 tensorRT。

模型 INT8 量化: 使用 MinMax 校准, 权重 per-channel, 激活 per-tensor 对称量化, convDTS 在插件内部完成 int8×int8→int32 累加与重量化, 最终量化模型在 x4 的情况下输出图片与原模型输出的 PSNR 达 41.2dB, 显存峰值占用从 2.6GB 降为了 1.7GB, 在 5070Ti 上推理速度提升到了 1.6 倍

使用 tensorrt-llm 实现 Qwen2.5-7B 的量化部署

基于 TensorRT-LLM 在单卡 RTX 5070 Ti (16GB) 上完成 Qwen2.5-7B-Instruct 的量化部署与评测, 最终生产方案为 FP8 权重量化 + BF16 KV cache。部署后 GSM8K 5-shot 数学推理准确率达 82.03%, 与原始模型 (81.27%) 持平无损; 推理峰值显存由 15.9GB 降至 10.6GB (-33%), 模型磁盘占用由 15GB 降至 8.2GB (-45%), 16GB 单卡由满载不可用变为可稳定支撑多请求并发服务; 批量推理输出吞吐 120+ tok/s、系统总吞吐 600+tok/s, 相对 transformers 推理提升约 3 倍。

职业技能

熟悉 Python, C/C++ 项目开发, 熟悉 Linux 常用操作指令
熟悉 QAT, PTQ, 对称/非对称量化, 以及 per-channel/per-tensor 等量化原理, 能够分析量化精度损失原因以提高模型精度
能够熟练对 onnx 模型进行计算图的修改, 同时针对自定义算子能够编写相应的 onnxruntime 计算 kernel
熟练使用 torch, 能够使用 torch 完成模型训练
熟悉使用 tensorRT, 能够结合 INT8/MinMax 校准对模型进行高精度部署
能够使用 cuda 编程完成计算加速, 实现高性能计算

自我评价

乐观积极且具有良好的抗压能力, 热爱学习, 具有良好的团队协作能力, 对模型部署有浓厚的兴趣, 对待工作认真有热情